



Proyecto Final

Minería de Datos Aplicada a México
en la Salud Pública

Universidad Nacional Autónoma de
México

Facultad de Ciencias

Materia: Almacenes y minería de datos

Profa

Jessica Santizo Galicia

Ayudantes:

Diego Antonio Villalba González

Ares Gael Castro Romero

Alumna:

Sanluis Castillo Daniela Alejandra No. Cuenta: 320091179

Fecha de entrega: 8/Junio/2026

1 Introducción

En México, las enfermedades crónicas no transmisibles (como la diabetes, la hipertensión y la obesidad) y las afecciones respiratorias agudas representan una de las mayores cargas para el sistema de salud pública. La detección temprana de factores de riesgo y la correcta asignación de recursos hospitalarios son críticas para reducir la mortalidad y optimizar la atención médica. El presente proyecto aplica técnicas avanzadas de minería de datos sobre los registros de salud nacional para identificar patrones ocultos en los pacientes y construir un modelo capaz de predecir la gravedad del estado de un paciente a partir de sus condiciones preexistentes.

1.1 Problema

El problema central es la dificultad de los centros de salud para estratificar de manera inmediata el nivel de riesgo de un paciente que ingresa con síntomas respiratorios agudos, considerando su historial de comorbilidades. Esto genera saturación en las Unidades de Cuidados Intensivos (UCI) debido a la falta de herramientas predictivas automatizadas en el triaje médico.

1.2 Importancia

Según datos oficiales de la Secretaría de Salud y el INEGI, México ocupa los primeros lugares mundiales en obesidad y diabetes. Cuando estas condiciones se combinan con infecciones respiratorias, el índice de letalidad aumenta drásticamente. Optimizar la predicción de hospitalización no solo salva vidas, sino que reduce el impacto económico y operativo en el sistema de salud pública mexicano.

1.3 Objetivo

Segmentar a la población afectada en grupos o perfiles de riesgo homogéneos para descubrir qué combinaciones de enfermedades crónicas (comorbilidades) detonan los peores pronósticos clínicos.

1.4 Dataset

URL del dataset: <https://www.gob.mx/salud/documentos/datos-abiertos-152127>

Se utilizará la base de datos abierta de la Dirección General de Epidemiología de la Secretaría de Salud de México. Por un lado, la rúbrica exige un mínimo de 100,000 filas y este archivo tiene 222,380 registros reales de pacientes del país, superando por mucho la meta. Además, cuenta con más de 20 columnas que combinan datos numéricos, como la edad, con datos categóricos como el sexo o la presencia de enfermedades crónicas, entre ellas la diabetes, la obesidad y el tabaquismo. Toda esta variedad de información nos servirá para hacer la limpieza de datos fácilmente, entrenar el modelo de predicción supervisado y agrupar a los pacientes en clusters de manera muy exacta.

2 Análisis Exploratorio de Datos

2.1 Descripción General

- **Fuente de los datos:** Dirección General de Epidemiología (DGE), Secretaría de Salud, México.
- **Fecha de extracción:** 2 de junio de 2026.
- **Dimensiones del dataset:** El conjunto de datos cuenta con un volumen real de **222,379 filas** (registros de pacientes) y **42 columnas** (variables independientes y objetivo).
- **Columnas:**

Nombre de la Columna	Tipo de Dato
FECHA_ACTUALIZACION	str
ID_REGISTRO	str
ORIGEN	int64
SECTOR	int64
ENTIDAD_UM	int64
SEXO	int64
ENTIDAD_NAC	int64
ENTIDAD_RES	int64
MUNICIPIO_RES	int64

Nombre de la Columna	Tipo de Dato
TIPO_PACIENTE	int64
FECHA_INGRESO	str
FECHA_SINTOMAS	str
FECHA_DEF	str
INTUBADO	int64
NEUMONIA	int64
EDAD	int64
NACIONALIDAD	int64
EMBARAZO	int64
HABLA LENGUA INDIG	int64
INDIGENA	int64
DIABETES	int64
EPOC	int64
ASMA	int64
INMUSUPR	int64
HIPERTENSION	int64
OTRA_COM	int64
CARDIOVASCULAR	int64
OBESIDAD	int64
RENAL_CRONICA	int64
TABAQUISMO	int64
OTRO_CASO	int64
TOMA_MUESTRA_LAB	int64
RESULTADO_PCR	int64
RESULTADO_PCR_COINFECCION	int64
TOMA_MUESTRA_ANTIGENO	int64
RESULTADO_ANTIGENO	int64
CLASIFICACION_FINAL_COVID	int64
CLASIFICACION_FINAL_FLU	int64
MIGRANTE	int64
PAIS_NACIONALIDAD	str
PAIS_ORIGEN	str
UCI	int64

2.2 Calidad de datos:

Variable	Valores Faltantes (<i>NaN</i>)	Porcentaje (%)
UCI	116,537	52.40
INTUBADO	116,537	52.40
OTRO_CASO	6,230	2.80
OTRA_COM	1,790	0.80
ASMA	291	0.13
EPOC	286	0.13
DIABETES	279	0.13
TABAQUISMO	262	0.12
CARDIOVASCULAR	223	0.10
HIPERTENSION	209	0.09

Al parecer no hay datos duplicados pero si hay faltantes.

En el diseño del sistema de salud en México, la pregunta sobre si un paciente ingresó a la Unidad de Cuidados Intensivos (UCI) está encadenada a su condición de ingreso. Si el paciente fue clasificado como ambulatorio (se va a su casa), automáticamente la opción "Cuidados Intensivos" recibe el código de control 97 ("No aplica").

Al igual que con la variable UCI, un médico en un triaje o clínica periférica no le asignará un ventilador mecánico asistido (INTUBADO) a un paciente ambulatorio que no requiere internamiento. Ambas variables se mueven en perfecta sincronía porque responden al mismo filtro operativo de los hospitales.

La variable OTRO_CASO indica si el paciente estuvo en contacto con otro caso confirmado de enfermedad respiratoria. Al tener apenas un 2.80% de códigos clasificados como "Se ignora" (98) o "No especificado" (99), vemos que el historial de contacto epidemiológico es una pregunta que los médicos llenan casi siempre con éxito.

2.3 Estadísticas descriptivas:

A partir de los cálculos generados sobre los 222,380 registros del dataset, se extrajeron las siguientes conclusiones estadísticas:

2.3.1 Edad

- **Media y mediana:** La edad promedio (media) de las personas en el dataset es de 35 años. Por otro lado, la mediana nos indica que exactamente la mitad de la población tiene 32 años o menos, lo que nos muestra que el conjunto de datos está cargado significativamente hacia una población joven.
- **Dispersión y Rango:** La desviación estándar es de 26.4 años, lo que significa que las edades varían bastante respecto al promedio. El rango completo va desde los 0 años (bebés recién nacidos) hasta los 121 años, cubriendo todo el ciclo de vida.
- **Distribución por bloques:** El 25% de las personas más jóvenes tienen 9 años o menos (Cuartil 1). El 75% de la población tiene 56 años o menos (Cuartil 3). Esto significa que el 25% restante corresponde a adultos mayores de entre 56 y 121 años.

2.3.2 Análisis de las Variables Categóricas

Para las variables cualitativas (categóricas), analizamos la "Moda", que simplemente representa la opción que más veces se repite en la base de datos:

- SEXO: El grupo más frecuente corresponde al sexo femenino, representando el 55.15% del total de casos (122,637 registros).
- TIPO_PACIENTE: La gran mayoría de las personas registradas, el 52.29% (116,289 pacientes), fueron atendidas de forma ambulatoria, es decir, no requirieron quedarse internadas en el hospital y pudieron llevar su recuperación en casa.
- El 86.87% de las personas no padecen diabetes.
- El 84.13% no sufren de hipertensión.
- El 93.39% no presentan problemas de obesidad.

Aunque la gran mayoría de la población registrada está sana de estas afecciones preexistentes, los porcentajes restantes (por ejemplo, casi un 16% con hipertensión y un 13% con diabetes) representan a decenas de miles de personas en riesgo, lo cual es un volumen muy importante

2.4 Valores Atípicos

Métrica Analítica	Valor
Primer Cuartil (Q_1)	9.00
Tercer Cuartil (Q_3)	56.00
Rango Intercuartílico (IQR)	47.00
Límite Superior ($Q_3 + 1.5 \times \text{IQR}$)	126.50
Cantidad de Registros Atípicos	0
Porcentaje de Atípicos (%)	0.00%

El umbral máximo aceptado para la distribución se fijó en 126.50 años. Dado que el registro más longevo en la base de datos es de 121 años, ningún paciente supera el límite matemático establecido, confirmando una tasa de atípicos del 0.00%. Por consiguiente, se determinó mantener la totalidad de los registros intactos; conservar estos datos es la decisión estadísticamente correcta en salud pública, ya que asegura que el modelo predictivo final considere de manera natural y real los casos de longevidad avanzada de la población mexicana sin incurrir en pérdidas artificiales de información histórica.

2.5 Relación entre variables

Al analizar los coeficientes, se observa una correlación positiva moderada entre la *Edad* y las enfermedades de *Hipertensión* (0.39) y *Diabetes* (0.31), lo que confirma que el riesgo de padecer estas comorbilidades se incrementa de forma natural con el envejecimiento. Asimismo, los valores más altos de la matriz se concentran entre el ingreso a terapia intensiva (*UCI*) y la necesidad de ventilación mecánica (*INTUBADO*) con un coeficiente de 0.68, reflejando la coherencia clínica del triaje médico. Dado que el resto de los atributos muestran correlaciones cercanas a cero, se concluye que las relaciones en el dataset no son lineales directas.

2.6 Variables Categóricas

Variable	Categoría	Frecuencia Absoluta	Porcentaje
SEXO	Mujer (Moda)	122,637	55.15%
	Hombre	99,743	44.85%
DIABETES	SÍ	29,440	13.23%
	NO (Moda)	192,940	86.87%
HIPERTENSIÓN	SÍ	35,470	15.87%
	NO (Moda)	186,910	84.13%
TIPO_PACIENTE (Variable Objetivo)	Ambulatorio (Moda)	116,289	52.29%
	Hospitalizado	106,091	47.71%

Por un lado, las variables que describen antecedentes médicos muestran una asimetría muy marcada; la enorme mayoría de los registros corresponden a pacientes que ingresaron sin un diagnóstico previo de enfermedades crónicas, acumulando un 86.87% en la categoría “NO” para Diabetes y un 84.13% para Hipertensión. En contraste, la distribución por género biológico refleja una muestra sumamente equilibrada y homogénea, donde el sexo femenino funge como la moda estadística con el 55.15% de las incidencias totales (122,637 casos), garantizando que ambos grupos están representados de forma equitativa para evitar sesgos demográficos en el análisis.

Por otra parte, el hallazgo analítico más relevante para el desarrollo del proyecto se localiza en la variable de respuesta clínica *TIPO_PACIENTE*. Los datos demuestran que el 52.29% de los pacientes (116,289 personas) recibieron atención de carácter ambulatorio, mientras que el 47.71% restante (106,091 personas) requirió ingresar a hospitalización. En el ámbito del aprendizaje automático, estos volúmenes determinan que las clases del dataset gozan de un **balance natural óptimo** (con una relación prácticamente simétrica cercana al 50/50).

3 Modelo Supervisado

3.1 Definición de Variables y Proceso de Preprocesamiento

El objetivo del modelo supervisado es resolver una tarea enfocada en predecir el destino clínico del paciente durante la clasificación inicial. Se definió como variable objetivo de estudio a la columna *TIPO_PACIENTE*, recodificada en un espacio binario estandarizado donde la clase 0 representa una resolución de carácter “Ambulatorio” y la clase 1 determina una necesidad estricta de “Hospitalización”. Como variables independientes de entrada (*features*) para nutrir al clasificador, se seleccionaron los atributos de *Edad*, *Sexo*, *Diabetes*, *Hipertensión* y *Obesidad*. El universo de datos se dividió fijando un esquema de 70% para el conjunto de entrenamiento y 30% para pruebas, estableciendo una semilla aleatoriamente fija (*random_state* = 42) para asegurar la reproducibilidad metodológica del experimento.

3.2 Entrenamiento, Evaluación e Interpretación Crítica

Se implementó y entrenó un modelo predictivo basado en el algoritmo de ensamble *Random Forest Classifier*, parametrizado con 100 estimadores secuenciales y una profundidad máxima de árbol limitada a 10 niveles con el fin de prevenir efectos de sobreajuste (*overfitting*). Los resultados cuantitativos obtenidos tras someter al clasificador al conjunto de validación independiente se detallan en la Tabla 2.

Table 2: Métricas del modelo supervisado

Métrica de Evaluación	Valor Obtenido
Accuracy Global del Modelo	71.08%
F1-Score	71.03%
Precision	71.30%
Recall	70.93%
Accuracy de Línea Base Trivial	52.29%

Hallazgos: El clasificador desarrollado demuestra un rendimiento robusto al alcanzar un Accuracy del 71.08%, superando de forma contundente la precisión de la línea base trivial (clasificador mayoritario de 52.29%) en un

margen de 29.13 puntos porcentuales, confirmando que las comorbilidades demográficas contienen suficiente peso discriminatorio para modelar el riesgo de ingreso hospitalario. El estado de la arquitectura entrenada fue persistido y guardado exitosamente en el disco bajo el formato serializado corporativo en la ruta `models/random_forest_model.joblib`, cumpliendo formalmente con las restricciones de desacoplamiento técnico y reutilización de software sin necesidad de reentrenamiento remoto.

4 Agrupamiento (Clustering)

4.1 Selección de Variables, Preprocesamiento y Justificación del Algoritmo

Con el propósito de descubrir perfiles clínicos ocultos y segmentar a la población bajo un enfoque de riesgo epidemiológico no supervisado, se seleccionaron como variables de estudio a la *Edad*, *Diabetes*, *Hipertensión* y *Obesidad*. El algoritmo seleccionado fue *K-Means* debido a su eficiencia matemática para procesar grandes volúmenes de datos basados en distancias de densidad compacta. Como paso de preprocesamiento obligatorio, todas las variables categóricas fueron convertidas a un espacio binario homogéneo (SÍ = 1, NO = 0) y el vector de características completo fue normalizado mediante una transformación de estandarización típica, asegurando que la magnitud de la variable de edad no sesgara.

4.2 Determinación de Grupos y Análisis Estadístico de Perfiles

Para establecer el número óptimo de clústeres, se evaluó la inercia intraclúster mediante el método matemático del codo, identificando un punto de inflexión o quiebre claro en el nivel $K = 3$. Las estadísticas descriptivas de las variables originales mapeadas hacia los tres segmentos resultantes se detallan en la siguiente tabla:

Etiqueta del Clúster	Edad Promedio	Diabetes	Hipertensión	Obesidad	Tamaño (Casos)
Clúster 0: Adulto Comórbido	64.0 años	62.60%	75.20%	0.00%	38,469
Clúster 1: Joven Saludable	27.2 años	0.10%	0.10%	0.00%	169,223
Clúster 2: Obesidad en Edad Madura	50.6 años	33.50%	42.00%	100.00%	14,687

Hallazgos: El *Clúster 1 (Joven Saludable)* constituye el sector mayoritario de la muestra, representando la línea basal de menor vulnerabilidad médica al registrar tasas nulas de comorbilidades. Por el contrario, el *Clúster 0 (Adulto Comórbido)* agrupa de forma pura el nicho de máximo riesgo, demostrando estadísticamente que en pacientes de la tercera edad (64 años promedio) la hipertensión y la diabetes actúan de forma conjunta y agresiva. Finalmente, el *Clúster 2 (Obesidad en Edad Madura)* aísla con un 100% de precisión el impacto del sobrepeso en edades intermedias, conviviendo de forma moderada con rasgos hipertensivos. Estos hallazgos enriquecen al modelo supervisado, confirmando que las variables predictoras no se distribuyen al azar, sino que se aglomeran en estructuras poblacionales de riesgo claramente identificables en el país.

5 Conclusiones

El desarrollo del presente proyecto permitió demostrar con éxito la viabilidad y el impacto de aplicar técnicas avanzadas de minería de datos sobre los registros de la Secretaría de Salud de México. A través del Análisis Exploratorio de Datos (EDA), se identificaron las características estructurales de la muestra, confirmando una población predominantemente joven pero con nichos críticos de comorbilidades crónicas acumuladas en la vejez.

El modelo supervisado, implementado mediante el algoritmo *Random Forest Classifier*, alcanzó un rendimiento robusto con un Accuracy global del 71.08% . Al superar por casi 20 puntos porcentuales la precisión de la línea base trivial (52.29%). La persistencia de esta arquitectura en un archivo serializado facilita su futura integración en sistemas de triaje automatizados, ofreciendo una herramienta de soporte analítico capaz de optimizar la asignación de camas y reducir la saturación operativa en situaciones de emergencia sanitaria.

Por su parte, el enfoque no supervisado con *K-Means* enriqueció sustancialmente los hallazgos predictivos. Las estructuras descubiertas aislaron con precisión desde la línea base mayoritaria y segura del país (*Joven Saludable* con 169,223 casos) hasta el foco rojo de vulnerabilidad extrema (*Adulto Comórbido* de la tercera edad), demostrando estadísticamente cómo interactúan el envejecimiento, la diabetes y la hipertensión de forma conjunta.

En conclusión, la sinergia entre ambos modelos prueba que la minería de datos no solo automatiza procesos predictivos aislados, sino que traduce

bases de datos masivas en conocimiento estratégico aplicable. Para la salud pública mexicana, estas metodologías representan un recurso invaluable para transitar de una medicina reactiva hacia una gestión hospitalaria preventiva, eficiente y guiada científicamente por la evidencia de los datos.

References

- [1] Dirección General de Epidemiología (DGE). (2026). *Base de Datos Abierta de Salud Pública - Registro de Enfermedades Respiratorias*. Secretaría de Salud, Gobierno de México. Extraído el 2 de junio de 2026 de <https://www.gob.mx/salud/documentos/datos-abiertos-152127>.
- [2] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281-297.
- [3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [4] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [5] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.